

Parte 1

Análisis de la base de datos

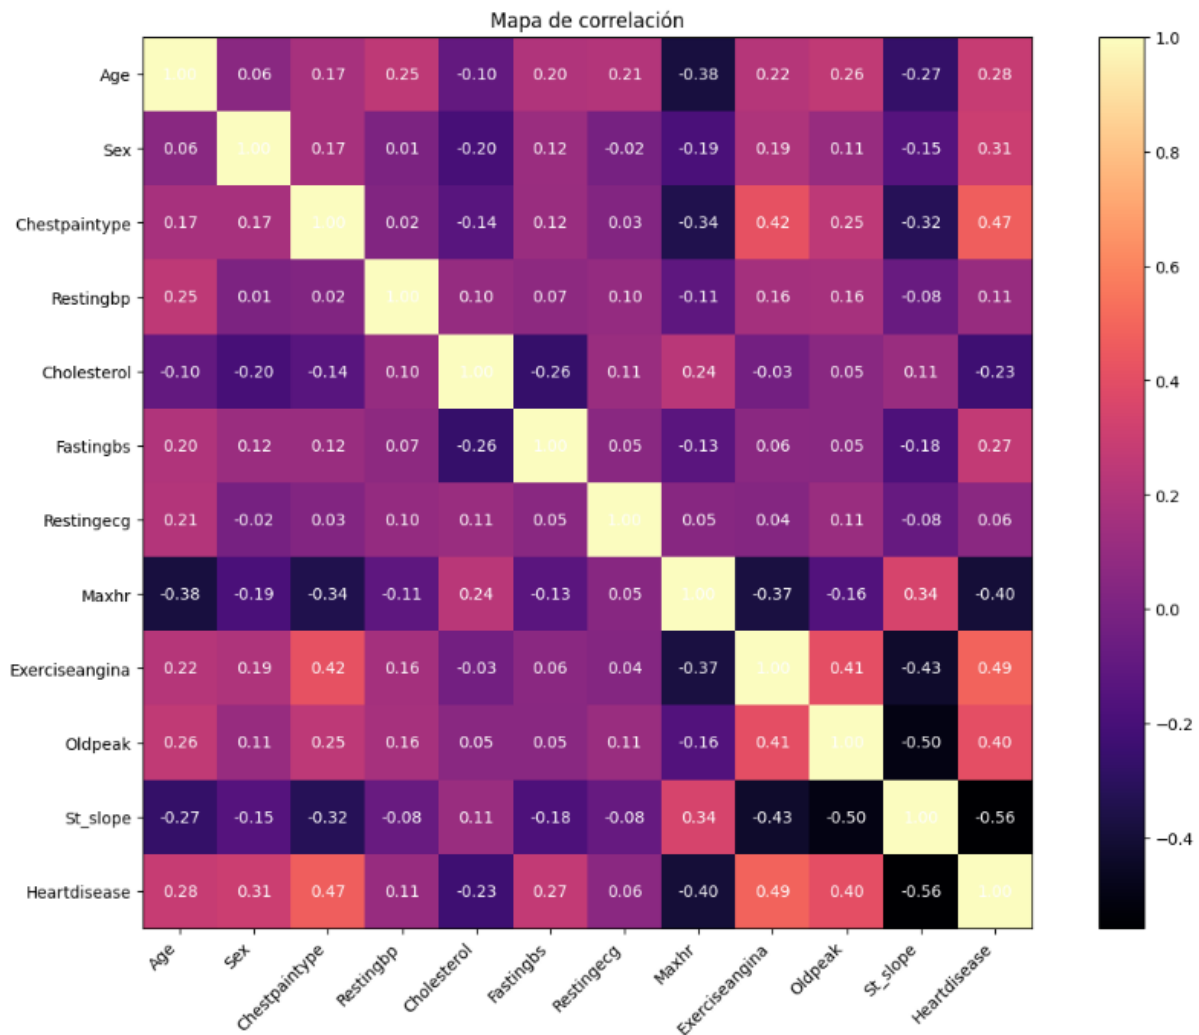
1. Describe cada columna del conjunto de datos: ¿Qué representa? ¿Es una variable categórica, continua, discreta, etc.?
- **Age/Edad:** Representa la edad de los pacientes, es una variable continua ya que puede tomar cualquier valor numérico.
 - **Sex/Sexo:** Describe el género (masculino o femenino) de la persona y es una variable binaria.
 - **ExerciseAngina:** Expresa la presencia o no de angina inducida por ejercicio, es una variable binaria donde 1 indica la presencia y 0 la ausencia.
 - **ChestPainType (Tipo de dolor de pecho):** Representa el tipo de dolor de pecho experimentado por el paciente, al ser un clasificador se trata de una variable categórica:
 - 1: Angina típica
 - 2: Angina atípica
 - 3: Dolor no anginal
 - 4: Asintomático
 - **RestingBP (Presión arterial en reposo):** Mide la presión arterial del paciente en reposo en mm Hg. Esta es una variable continua ya que toma cualquier valor numérico con precisión.
 - **Cholesterol (Colesterol):** Es una variable continua que mide el colesterol en mg/dl obtenido a través de un sensor de IMC.
 - **FastingBS (Azúcar en ayunas):** Variable binaria donde el valor 1 indica que el nivel de azúcar en ayunas es mayor a 120 mg/dl.
 - **RestingECG (Resultados del electrocardiograma en reposo):** Es una variable categórica que describe los resultados del electrocardiograma en reposo:
 - 0: Normal
 - 1: Anormalidad en la onda ST¹
 - 2: Hipertrofia ventricular izquierda probable o definitiva según el criterio de Estes²
 - **MaxHR (Frecuencia cardíaca máxima):** Esta es una variable numérica continua que mide la frecuencia cardíaca máxima alcanzada durante la evaluación.

¹ La anormalidad en la onda ST-T se refiere a cualquier desviación o irregularidad en las ondas ST o T del electrocardiograma (ECG). Las ondas ST y T son parte del ciclo del ECG y reflejan el comportamiento eléctrico del corazón, específicamente durante la repolarización ventricular.

² El **Criterio de Estes**, también conocido como **Puntaje de Estes para Hipertrofia Ventricular Izquierda (HVI)**, es un sistema de puntuación utilizado para diagnosticar la hipertrofia ventricular izquierda en un electrocardiograma (ECG).

- **ST_Slope:** Representa la pendiente del segmento ST³ en el electrocardiograma. Es una variable categórica con valores:
 - 0: Pendiente descendente
 - 1: Pendiente plana
 - 2: Pendiente ascendente
- **Oldpeak:** Representa la depresión del segmento ST medida en milímetros. Es una variable numérica continua.
- **HeartDisease (Output/Objetivo):** Esta es la variable de salida binaria que indica la probabilidad de un ataque cardíaco:
 - 0: Menor probabilidad de ataque cardíaco
 - 1: Mayor probabilidad de ataque cardíaco

2. Análisis de Correlaciones: Usa correlaciones para evaluar si las características son relevantes para la tarea de clasificación. Identifica las relaciones entre las características y la columna objetivo.



³ El **segmento ST** es una parte del electrocardiograma (ECG) que representa el período entre la despolarización y la repolarización de los ventrículos del corazón. Este segmento es normalmente una línea plana (isoelectrica) que se encuentra entre el final del complejo QRS y el inicio de la onda T12.

¿Cuáles parecen ser las más influyentes?

La imagen nos muestra un mapa de calor haciendo referencia a las correlaciones entre las columnas. Con respecto a las relaciones entre las características y la columna objetivo, podemos notar que varias columnas tienen una correlación moderada con la columna de salida, lo que indica una relación apreciable. Entre ellas se encuentran:

- ChestPainType (Tipo de dolor de pecho).
- MaxHR (Máxima frecuencia cardiaca alcanzada).
- ExerciseAngina (angina inducida por ejercicio).
- Oldpeak (ST).
- ST_Slope (pendiente ST).

Por otro lado, podemos ver que hay algunas características que tienen una correlación débil, pero que pueden aportar al entrenamiento de la red neuronal como la edad, el sexo de la persona y el azúcar en ayunas.

Por último, mirando el gráfico, se pueden ver características con una correlación muy débil. Entre las cuales figuran:

- RestingBP (Presión arterial en reposo).
- Cholesterol (Colesterol).
- RestingECG (Electrocardiograma en reposo).

3. Análisis de Factibilidad: ¿Es esta base de datos adecuada para entrenar una red neuronal de clasificación? Justifica tu respuesta en base a los datos. Explica el propósito de entrenar la red. ¿Qué intentará predecir? ¿Cuál es el objetivo del modelo?

Podemos decir que este dataset es adecuado para entrenar una red neuronal de clasificación binaria para predecir el riesgo de ataque cardíaco por las siguientes razones:

Cantidad y calidad de datos:

En este dataset contamos con 918 registros de personas lo cual creemos que es suficiente para entrenar a una red neuronal sencilla. Con un número moderado de datos, creemos que la red puede aprender patrones sin verse afectada por un sobreajuste.

Cantidad de características:

Esta base de datos también presenta una cantidad de columnas con características adecuadas para utilizar los datos de entrada, además la gran mayoría de las características son altamente importantes para la salud cardíaca, por lo tanto consideramos que serán fundamentales para el entrenamiento de la red neuronal.

Propósito de los datos:

La red neuronal tendrá como objetivo tratar de predecir el riesgo de un ataque cardíaco en una persona, la salida del modelo será binaria, donde 0 indica menor probabilidad y 1 mayor probabilidad de padecer un infarto. Creemos que al tener una salida binaria, la red neuronal será más eficiente.

4. Datos Atípicos y Limpieza de Datos: Identifica datos atípicos (outliers) en las columnas relevantes. ¿Es necesario limpiarlos? Si decides hacerlo, justifica tu decisión y describe cómo lo harías. Si no, explica por qué preferís dejarlos.

Para los datos atípicos nos enfocamos en aquellas columnas cuya variable es numérica continua:

- Age/Edad.
- RestingBP.
- Cholesterol.
- MaxHR.
- Oldpeak.

Mediante el siguiente código pudimos filtrar los datos atípicos de la muestra

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Seleccionar las columnas numéricas para hacer el análisis
numeric_columns = ['Age', 'RestingBP', 'Cholesterol', 'MaxHR', 'Oldpeak']


# Creamos los boxplots para visualizar los datos atipicos
plt.figure(figsize=(15, 8))
for i, col in enumerate(numeric_columns, 1):
    plt.subplot(2, 3, i) # Crear subimagenes(dos filas de tres columnas, i la posicion de cada grafico)
    sns.boxplot(df[col])
    plt.title(f'Boxplot de {col}')
plt.tight_layout()
plt.show()

# Eliminamos los datos atipicos
def remove_outliers(df, columns):
    Q1 = df[columns].quantile(0.25)
    Q3 = df[columns].quantile(0.75)
    IQR = Q3 - Q1
    return df[~((df[columns] < (Q1 - 1.5 * IQR)) | (df[columns] > (Q3 + 1.5 * IQR))).any(axis=1)]

# Eliminar outliers
df = remove_outliers(df, numeric_columns)
```

Decidimos sacar los valores atípicos ya que como estamos en un contexto de salud, algunos de ellos podrían representar errores de medición o registros atípicos irrelevantes para el análisis. Ahora contamos con 702 muestras. Nuestro mapa de correlaciones se encuentra descrito de la siguiente manera

Trabajo Practico Final Matemática 3
Fernandez Mariano
Moro Martín




5. Transformaciones Preliminares: Realiza las transformaciones necesarias a los datos, por ejemplo, normalización, conversión de categorías a valores numéricos, etc. Explica por qué estas transformaciones son necesarias.

En nuestro dataframe decidimos normalizar los datos para que la red neuronal trabaje con rangos de valores similares, lo cual notamos que mejora la velocidad, la eficiencia y aprendizaje de la misma.

Luego no fue necesario eliminar valores nulos; si tuvimos que codificar variables categóricas, como por ejemplo el sexo de la persona.

Parte 2 Desarrollo de la red neuronal

1. Arquitectura de la red



¿Cuántas capas tendrá la red?, ¿Cuántas neuronas habrá en cada capa?

Nuestra red neuronal cuenta con dos capas, **una oculta** y otra de **salida**. En la **capa oculta** enumeramos **9 neuronas**, que están conectadas a **11 neuronas en la capa de entrada**, entre ellas todas las columnas mencionadas anteriormente. No obstante en nuestra red neuronal, en su **capa de salida**, contará con **una sola neurona**.

¿Qué función de activación utilizará cada capa? Explica por qué elegiste esas funciones de activación.


La capa oculta utilizará la función de activación ReLU ya que es computacionalmente rápida y económica en términos de rendimiento.

Luego la capa de salida se maneja con la función de activación logística. La cual viene bien para clasificaciones binarias como la que implementaremos. Si el valor de salida es mayor o igual a 0.5, la red neuronal estima que la persona tienda a sufrir un ataque cardíaco, en cambio si el valor es menor al dicho anteriormente, podría decirse que es probable que el sujeto **no** sufra un infarto.

4. Análisis de Overfitting:

- Analiza si tu modelo presenta overfitting.
- ¿Cómo se puede identificar el punto en el que el modelo empieza a sobreajustarse a los datos de entrenamiento? ¿Cómo lo manejarías?


Luego de analizar y comparar los gráficos de precisión de los datos de entrenamiento y los datos de testeo, sobre las iteraciones de la red neuronal, podemos ver que no se presenta overfitting en nuestra red.



De todas maneras, durante el desarrollo de nuestra red neuronal, en algunos casos pudimos observar overfitting en los gráficos en el punto en qué, la precisión en los datos de prueba se mantenía constante mientras que la precisión en los datos de entrenamiento seguía creciendo, separándose de la precisión de testeo, esto quiere decir que frente a datos nuevos no tenía el

Trabajo Practico Final Matemática 3
Fernandez Mariano
Moro Martín

mismo rendimiento que con los datos que entrenó, por lo tanto se puede deducir que la red aprendió “de memoria” los datos de entrenamiento. Mediante algunas pruebas este problema lo pudimos solucionar modificando la cantidad de iteraciones, el paso de aprendizaje y la cantidad de neuronas en nuestra capa oculta. Por ejemplo, en la siguiente imagen se puede ver el punto en el que se separan las curvas:



Parte 3

Comparación con scikit-learn

Comparación de Rendimiento: Compara el rendimiento de la red neuronal implementada en numpy con la que implementaste en scikit-learn.

¿En qué aspectos los resultados son similares?

¿En qué aspectos son diferentes?

Compara las curvas de entrenamiento y validación, el tiempo de ejecución, y cualquier otro aspecto relevante.

El rendimiento de la red neuronal implementada en scikit-learn se puede notar un poco más eficiente con respecto a la implementada en numpy, es mucho más rápida en términos de ejecución y está más optimizada, sin embargo, pudimos ajustar la red implementada en numpy de tal manera que notamos resultados bastantes parecidos a los de scikit-learn.

También notamos que scikit-learn es capaz de entrenar la red neuronal con menos iteraciones en comparación a nuestra red neuronal con numpy, a esto se debe su mayor rapidez.

Parte 4

Conclusiones finales

Incluí una sección final en tu reporte donde reflexiones sobre todo el proceso. ¿Qué aprendiste sobre la construcción de redes neuronales desde cero? ¿Cuáles son las ventajas y desventajas de hacerlo manualmente versus usar una librería como scikit-learn?

Durante la implementación de la red neuronal desde cero, pudimos entender mejor la lógica que se implementa para construirla. Al hacerla manualmente, con ayuda del apunte y la guía del trabajo práctico, nos facilitó el desarrollo de la misma. Aprendimos el paso a paso del aprendizaje de la red neuronal, tanto la parte analítica de los datos, como la parte matemática, incluyendo las multiplicaciones matriciales, el descenso de gradiente, las funciones de costo y derivadas, además de la arquitectura de una red neuronal.

Abajo enumeramos las ventajas y desventajas de hacer la implementación manualmente y con Scikit-Learn:

1. Ventajas de haber construido la red desde 0:

- **Control del código:** Tuvimos la libertad de modificar funciones, números, testear con diferentes tasas de aprendizaje, distintas iteraciones; con la finalidad de encontrar la mejor precisión.
- **Control de errores:** Se pueden implementar gráficos que muestran el aprendizaje de la red neuronal, lo que permite verificar si hay overfitting, por ejemplo.

2. Desventajas de haber construido la red desde 0:

- **Complejidad:** Es un proceso complejo, en particular notamos que nos equivocamos en partes diminutas del código que costó tiempo notarlas y arreglarlas.
- **Ejecución:** Si bien nuestra red neuronal es simple, el tiempo de ejecución es bastante largo.

3. Ventajas de usar Scikit-Learn:

- **Simpleza:** Con Scikit-Learn el código es mucho más sencillo y rápido de implementar.
- **Eficiencia:** Su tiempo de ejecución es mucho menor comparado con la red construida desde 0 y más acertado.

4. Desventajas de usar Scikit-Learn:

- **Visibilidad:** Al usar una librería como Scikit-Learn, consideramos que es una desventaja importante no saber cómo funciona el proceso por dentro.
- **Control de errores:** No hay una manera fácil de detectar errores, no proporciona una herramienta para graficar el aprendizaje y el overfitting

solo se detecta viendo la diferencia entre la precisión de entrenamiento con la de testeo.

Conclusión: Construir redes neuronales manualmente y usar librerías como Scikit-Learn son enfoques que se pueden complementar, de esta forma se pueden aprovechar las ventajas de cada herramienta, por ejemplo, simular cambios de la red neuronal con las librerías y, por otro lado, manejar y visualizar los errores manualmente.